

STAT404 - 베이지통계입문

Progress Report

평균장 방법과 변분 베이지

Presenter: 윤민서
데이터과학과 2021320322

Scope and Purpose

- 변분 추론
 - 평균장 방법
 - 변분 베이즈
- 베이지안 최적화

Scope and Purpose

- 목표
 - 수식 전개
 - 두 방법에 대해 각각 서로 다른 subtask에 적용
 - 평균장 방법: 이미지 잡음 제거
 - 변분 베이지스: 선형 회귀
 - 각 방법에서 사용되는 초모수를 베이지안 최적화 방법으로 조정

Literature Review

- 수식 전개

- <https://probml.github.io/pml-book/book0.html>

21	<i>Variational inference</i>	731
21.1	Introduction	731
21.2	Variational inference	732
21.2.1	Alternative interpretations of the variational objective	733
21.2.2	Forward or reverse KL? *	733
21.3	The mean field method	735
21.3.1	Derivation of the mean field update equations	736
21.3.2	Example: mean field for the Ising model	737
21.4	Structured mean field *	739
21.4.1	Example: factorial HMM	740
21.5	Variational Bayes	742
21.5.1	Example: VB for a univariate Gaussian	742
21.5.2	Example: VB for linear regression	746
21.6	Variational Bayes EM	749
21.6.1	Example: VBEM for mixtures of Gaussians *	750
21.7	Variational message passing and VIBES	756
21.8	Local variational bounds *	756
21.8.1	Motivating applications	756
21.8.2	Bohning's quadratic bound to the log-sum-exp function	758
21.8.3	Bounds for the sigmoid function	760
21.8.4	Other bounds and approximations to the log-sum-exp function *	762
21.8.5	Variational inference based on upper bounds	763

Progress

- 평균장 방법

평균장 근사 수식 증명

평균장 근사를 위한 접근에서는 posterior를 fully factorized approximation 형태로 가정한다.

$$q(\mathbf{x}) = \prod_i q_i(\mathbf{x}_i)$$

우리의 목표는 아래의 최적화 문제를 푸는 것이다.

$$\min_{q_1, \dots, q_D} \mathbb{KL}(q||p)$$

즉 각 주변확률분포인 q_i 의 모수에 대하여 최적화한다.

변분 추론의 근본적인 목표는 다음의 하계를 최대화하는 것이다.

$$L(q) := -J(q) = \sum_{\mathbf{x}} q(\mathbf{x}) \log \frac{\tilde{p}(\mathbf{x})}{q(\mathbf{x})} \leq \log p(\mathcal{D})$$

이때 q_j 를 제외한 나머지 변수를 상수로 취급하면

$$\begin{aligned} L(q_j) &= \sum_{\mathbf{x}} \prod_i q_i(\mathbf{x}_i) \left[\log \tilde{p}(\mathbf{x}) - \sum_k \log q_k(\mathbf{x}_k) \right] \\ &= \sum_{\mathbf{x}_j} \sum_{\mathbf{x}_{-j}} q_j(\mathbf{x}_j) \prod_{i \neq j} q_i(\mathbf{x}_i) \left[\log \tilde{p}(\mathbf{x}) - \sum_k \log q_k(\mathbf{x}_k) \right] \\ &= \sum_{\mathbf{x}_j} q_j(\mathbf{x}_j) \sum_{\mathbf{x}_{-j}} \prod_{i \neq j} q_i(\mathbf{x}_i) \log \tilde{p}(\mathbf{x}) \\ &= \sum_{\mathbf{x}_j} q_j(\mathbf{x}_j) \sum_{\mathbf{x}_{-j}} \prod_{i \neq j} q_i(\mathbf{x}_i) \left[\log \tilde{p}(\mathbf{x}_{-j}) + \log \tilde{p}(\mathbf{x}_j) \right] \end{aligned}$$

Progress

- 변분 베이지스

변분 베이지스 수식 증명 - 선형 회귀

Prior: $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\mathbf{0}, \alpha^{-1}\mathbf{I})$

Likelihood: $p(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}) = \mathcal{N}(\mathbf{X}\mathbf{w}, \lambda^{-1})$

이때 α 와 λ 에 대한 추정을 한다고 하면 아래와 같은 prior를 고려할 수 있다.

$$p(\mathbf{w}, \lambda, \alpha) = \mathcal{N}(\mathbf{w}|\mathbf{0}, (\lambda\alpha)^{-1}\mathbf{I})\text{Ga}(\lambda|a_0^\lambda, b_0^\lambda)\text{Ga}(\alpha|a_0^\alpha, b_0^\alpha)$$

또한 posterior q 를 계산하기 편한 형태로 인수분해하여 근사하는 방법을 사용할 수 있다.

$$q(\mathbf{w}, \alpha, \lambda) = q(\mathbf{w}, \lambda)q(\alpha)$$

이러한 가정 하에서 Design and Analysis of Learning Classifier Systems의 7장의 내용에 따르면 posterior 아래와 같이 계산할 수 있다.

$$q(\mathbf{w}, \alpha, \lambda) = \mathcal{N}(\mathbf{w}|\mathbf{w}_N, \lambda^{-1}\mathbf{V}_N)\text{Ga}(\lambda|a_N^\lambda, b_N^\lambda)\text{Ga}(\alpha|a_N^\alpha, b_N^\alpha)$$

이때

$$\mathbf{V}_N^{-1} = \bar{\mathbf{A}} + \mathbf{X}^T\mathbf{X}$$

$$\mathbf{w}_N = \mathbf{V}_N\mathbf{X}^T\mathbf{y}$$

$$a_N^\lambda = a_0^\lambda + \frac{N}{2}$$

$$b_N^\lambda = b_0^\lambda + \frac{1}{2}(\|\mathbf{y} - \mathbf{X}\mathbf{w}\|^2 + \mathbf{w}_N^T\bar{\mathbf{A}}\mathbf{w}_N)$$

$$a_N^\alpha = a_0^\alpha + \frac{D}{2}$$

Remaining Work

- (저번 Progress report와 비교했을 때) 모델 성능 향상
- 시간이 된다면 더욱 다양한 task에 적용
- 초모수를 베이지안 최적화 방법으로 조정

Expected results

- 베이지안 최적화 방법으로 찾은 초모수가 모델 성능 향상에 상당히 기여를 할 것
 - 격자 탐색, 무작위 탐색에 비하여 시간적으로 효과적
- 사전 분포의 모수도 베이지안 최적화 방법으로 조정할 수 있다면 사전적인 믿음을 부여하는 것을 자동화할 수 있음

Questions?
